

Data-integraatioputki Azure-ympäristössä

Janne Kujala · Data Factory: Copy Pipeline & Mapping Data Flow · Microsoft Azure

Ongelma


Tavoitteena oli rakentaa Azure-ympäristöön käytännöllinen data-integraatioprosessi: siirtää dataa automaattisesti lähteestä kohteeseen ja muokata sitä matkalla käyttökelpoiseksi raportointia ja analytiikkaa varten. Harjoitus kattoi kaksi tyypillistä data-alustan perustarvetta: toistuvan, ajastetun datansiirron sekä datan suodatuksen ja aggregoinnin ennen tallennusta.

Arkkitehtuuri


Ratkaisu rakennettiin Azure Data Factoryn ympärille kahdessa osassa:

- **Copy Pipeline** — data kopioidaan Azure Blob Storagesta Azure SQL Databaseeseen, ajastettuna toistumaan automaattisesti ilman manuaalista käynnistystä.
- **Mapping Data Flow** — data luetaan Azure Data Lake Storage Gen2:sta, suodatetaan (vuosiluku ja genre) ja aggregoidaan (keskiarvoluokitus vuosittain) ennen tallennusta kohteeseen.


1. Automaattinen kopiointi




2. Datan muokkaus ennen tallennusta



Kuva 1. Ratkaisun kokonaisarkkitehtuuri: automaattinen kopiointi (ylhäällä) ja datan muokkaus mapping data flow'lla (alhaalla).




Kuva 2. Copy-pipeline Azure Data Factoryssä — data siirretään Blob Storagesta Azure SQL Databaseeseen.



Kuva 3. Mapping data flow: lähde → suodatus (FilterYears) → aggregointi (AggregateComedyRatings) → kohde.

Tulos

- Copy-pipeline validoitiin ja ajettiin onnistuneesti — data siirtyi oikein Blob Storagesta SQL-tietokantaan.
- Ajastettu triggeri ajoi putken toistuvasti ilman manuaalista käynnistystä — kaikki ajot onnistuivat (Succeeded).
- Mapping data flow suodatti ja aggregoi elokuva-datasetin (272 riviä) oikein genren ja vuosiluvun perusteella; tulos tarkistettiin data preview -näkylässä ennen ajon suorittamista.



Kuva 4. Onnistunut pipeline-ajo ja suorituskykytiedot (Blob Storage → SQL Database).

Triggered	Debug	Rerun	Cancel options	Refresh	Edit columns	List	Gantt
Filter by run ID or name	Local time : Last 24 hours	Pipeline name : All	Status : All	Copy filters	Export to CSV		
Runs : Latest runs	Triggered by : All	Add filter					
Showing 1 - 6 items							
Last refreshed 0 minutes ago							
☐	Pipeline name ↑↓	Run start ↑↓	Run end ↑↓	Duration	Triggered by	Status ↑↓	
☐	CopyPipeline	5/3/2026, 11:15:00 AM	5/3/2026, 11:15:17 AM	18s	RunEveryMinute	✓ Succeeded	
☐	CopyPipeline	5/3/2026, 11:14:00 AM	5/3/2026, 11:14:17 AM	17s	RunEveryMinute	✓ Succeeded	
☐	CopyPipeline	5/3/2026, 11:13:00 AM	5/3/2026, 11:13:18 AM	18s	RunEveryMinute	✓ Succeeded	
☐	CopyPipeline	5/3/2026, 11:12:00 AM	5/3/2026, 11:12:21 AM	22s	RunEveryMinute	✓ Succeeded	
☐	CopyPipeline	5/3/2026, 11:11:02 AM	5/3/2026, 11:11:20 AM	19s	RunEveryMinute	✓ Succeeded	
☐	CopyPipeline	5/3/2026, 10:47:16 AM	5/3/2026, 10:47:38 AM	22s	Manual trigger	✓ Succeeded	

Kuvasta nähdään, että pipeline on ajettu useita kertoja onnistuneesti ajastuksen mukaisesti.

Kuva 5. Ajastettu automaatio: useita peräkkäisiä onnistuneita ajoja.

id	movie	title	genre	year	rating	number of votes
8511	Immigrant, The	Comedy	1917	4	59	
3309	Doc's Life, A	Comedy	1917	3	83	
72626	Billy Blazes, Esq.	ComedyWestern	1918	2	63	
3310	Kid, The	ComedyDrama	1921	8	57	
83096	Haunted House, The	Comedy	1920	9	61	
83318	Goat, The	Comedy	1921	8	86	

Kuva 6. Suodatettu ja tarkistettu data data preview -näkylässä.

Jatkokehitys

Seuraavina askelina ratkaisua voisi laajentaa virheen käsittelyllä, lokituksella ja monitoroinnilla ongelmien nopeaa havaitsemista varten, datan laadun tarkistuksilla ennen tallennusta sekä yhdistämällä useampia datalähteitä monimutkaisempiin muunnoksiin.

Käytetyt teknologiat: Azure Data Factory · Azure Blob Storage · Azure SQL Database · Azure Data Lake Storage Gen2 · Mapping Data Flows